

Reporte Técnico de Actividades Práctico-Experimentales Nro. 002

1. Datos de Identificación del Estudiante y la Práctica

Nombre del estudiante(s)	Ivett Anahi Zaragocin Mora
Asignatura	Simulación
Ciclo	5
Unidad	U1: Introducción a la Simulación
Resultado de aprendizaje de la unidad	R1. Aplica análisis estadísticos de los datos de la Simulación para mejorar la calidad de los resultados, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	02
Título de la Práctica	Comparación de modelos determinísticos, estocásticos, discretos y continuos
Nombre del Docente	José O. Guamán Q.
Fecha	08 y 09 de octubre de 2026
Horario	Jueves 10h30 a 11h30 · Viernes 07h30 a 09h30
Lugar	Aula
Tiempo planificado en el Sílabo	3 horas

2. Objetivo(s) de la Práctica

Diferenciar los principales paradigmas de simulación mediante la construcción de modelos computacionales.

1. Implementar un modelo determinístico y uno estocástico.
2. Comparar modelos discretos y continuos.
3. Analizar el efecto de la aleatoriedad sobre los resultados.

3. Materiales, Reactivos, Equipos y Herramientas

Materiales y reactivos:

- Python 3.12.
- NumPy 1.26 (cálculo numérico y generación de números aleatorios).
- Matplotlib 3.9 (gráficas).

Equipos y herramientas:

- Computador con sistema operativo Linux.
- Editor de código y Git/GitHub para el control de versiones.

4. Marco Conceptual

Un modelo de simulación representa el comportamiento de un sistema mediante variables, parámetros, ecuaciones y reglas. En esta práctica el sistema de estudio es el **crecimiento poblacional**, que se modela de cuatro formas.

Modelo determinístico. No usa aleatoriedad: con los mismos parámetros siempre produce el mismo resultado. Se usa el crecimiento exponencial, donde P_0 es la población inicial, r la tasa de crecimiento y t el tiempo:

$$P(t) = P_0 \cdot e^{rt}$$

Modelo discreto. La población cambia solo en intervalos de tiempo definidos (períodos enteros):

$$P_{t+1} = P_t + r \cdot P_t$$

Modelo estocástico. Incorpora una variable aleatoria con distribución normal de media 0, donde σ representa el nivel de variabilidad del sistema. Cada ejecución produce un resultado distinto:

$$P_{t+1} = P_t + r \cdot P_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma^2)$$

Modelo continuo. Supone que la población cambia en todo instante, según la ecuación diferencial $dP/dt = rP$. Se resuelve numéricamente con el **método de Euler**, donde Δt es el tamaño del paso:

$$P_{t+\Delta t} = P_t + \Delta t \cdot (r \cdot P_t)$$

5. Procedimiento / Metodología Ejecutada

1. Se tomaron los datos de la guía: [1000, 1100, 1250, 1400, 1600, 1850, 2100], que representan la población observada en 7 períodos.
2. A partir de los datos se estimaron los parámetros:
 - $P_0 = 1000$ (primer dato).
 - $r = 0.1318$, promedio de la tasa de crecimiento por período $(P_{t+1} - P_t)/P_t$.
 - $\sigma = 24.50$, desviación estándar del residuo entre los datos y la predicción del modelo discreto.
 - tiempo = 6 períodos y $\Delta t = 0.1$ para el modelo continuo.
3. Se implementaron los cuatro modelos en Python siguiendo el pseudocódigo de la guía, con arquitectura Modelo-Vista-Controlador. En el estocástico, si la población queda negativa se fija en 0. Se usó una semilla fija (42) para que las corridas sean reproducibles.
4. Se escribieron pruebas unitarias que verifican cada fórmula: por ejemplo, el estocástico con $\sigma = 0$ es igual al discreto, y Euler con $\Delta t = 1$ también es igual al discreto.
5. Se ejecutaron los cuatro modelos y se compararon con los datos mediante el error medio absoluto (MAE) y la raíz del error cuadrático medio (RMSE).
6. Se analizaron tres escenarios: distintas tasas r (positivas y negativas), distintos niveles de ruido σ (30 corridas cada uno) y distintos pasos Δt .

6. Resultados

Población por período

t	Datos	Determinístico	Discreto	Estocástico	Continuo (Euler)
0	1000	1000.0	1000.0	1000.0	1000.0
1	1100	1140.8	1131.8	1139.2	1139.9
2	1250	1301.5	1280.9	1263.9	1299.3
3	1400	1484.8	1449.7	1448.8	1481.0
4	1600	1694.0	1640.7	1662.7	1688.1
5	1850	1932.5	1856.9	1834.0	1924.2
6	2100	2204.7	2101.6	2043.8	2193.4

Error frente a los datos

Modelo	MAE	RMSE
Determinístico	65.49	73.81
Discreto	23.07	29.61
Estocástico	33.83	40.47
Continuo (Euler)	60.85	68.22




Figura 1. Los cuatro modelos frente a los datos observados.

Interpretación. El modelo discreto es el que mejor se ajusta a los datos (MAE 23.07), porque los datos son observaciones por período y r se estimó como tasa por período; su solución cerrada es $P_t = P_0(1 + r)^t$. El determinístico y el continuo sobreestiman la población (≈ 2200 frente a 2100 en $t = 6$):

con la misma r , $e^r = 1.1409$ es mayor que $1 + r = 1.1318$, porque el crecimiento continuo se acumula a cada instante. La tasa continua equivalente sería $\ln(1 + r) \approx 0.1238$.




Figura 2. Influencia de la tasa r : crecimiento ($r > 0$), equilibrio ($r = 0$) y decrecimiento ($r < 0$).

Influencia de r . La tasa determina la dirección y la velocidad del cambio. Con $r > 0$ la población crece de forma exponencial (2102 con $r = 0.1318$; 2986 con $r = 0.20$). Con $r = 0$ se mantiene constante, y con $r < 0$ decrece hacia 0 (262 con $r = -0.20$). Como el crecimiento es exponencial, una diferencia pequeña en r se amplifica con el tiempo.




Figura 3. Efecto del nivel de ruido σ : 30 corridas del modelo estocástico para $\sigma = 12.3$, 24.5 y 98.0 .

Efecto de la aleatoriedad. Con σ pequeño las corridas casi coinciden con el modelo discreto. Al aumentar σ , las trayectorias se separan cada vez más: la desviación estándar de la población final pasa de 28 a 84 y a 381. Con $\sigma = 98$ incluso aparecen corridas que decrecen temporalmente aunque $r > 0$. Sin embargo, el promedio de las corridas se mantiene cerca del discreto, porque el ruido tiene media 0.




Figura 4. Efecto del tamaño de paso Δt en el modelo continuo, frente a la solución exacta.

Discreto frente a continuo. Con $\Delta t = 1$, el método de Euler es idéntico al modelo discreto (error final 103.2 frente a la solución exacta). Al reducir Δt el error disminuye: 54.3 con $\Delta t = 0.5$, 11.4 con $\Delta t = 0.1$ y 1.1 con $\Delta t = 0.01$. Es decir, Euler converge al modelo continuo exacto cuando Δt tiende a 0.

7. Preguntas de Control

1. ¿Qué representa el arreglo de entrada?

La población observada del sistema real en 7 períodos consecutivos. De él se obtienen los parámetros P_0 , r y σ , y sirve como referencia para medir el error de cada modelo.

2. ¿Cuál es la diferencia entre un modelo determinístico y uno estocástico?

El determinístico siempre produce el mismo resultado con los mismos parámetros. El estocástico incluye una variable aleatoria (ϵ), por lo que cada ejecución da un resultado distinto y debe analizarse con varias corridas (promedio y dispersión).

3. ¿Qué efecto produce modificar la tasa (r)?

Controla la dirección y la velocidad del cambio: una r mayor produce un crecimiento más rápido, $r = 0$ mantiene la población constante y $r < 0$ produce decrecimiento. Por ser un modelo exponencial, una diferencia pequeña en r se amplifica con el tiempo.

4. ¿Qué representa el parámetro σ ?

Es la desviación estándar del ruido ϵ : el nivel de variabilidad o incertidumbre del sistema, causado por factores que el modelo no considera (clima, enfermedades, migración).

5. ¿Qué ocurre cuando aumenta el nivel de ruido?

Las trayectorias se separan más entre sí y del modelo sin ruido, y aumenta la incertidumbre del resultado final (de 28 a 381 de desviación al pasar de $\sigma = 12.3$ a $\sigma = 98$). La tendencia promedio no cambia, porque el ruido tiene media 0.

6. ¿Cuál es la diferencia entre los modelos discreto y continuo?

El discreto actualiza la población a saltos, una vez por período. El continuo supone que cambia en todo instante ($dP/dt = rP$), por lo que, con la misma r , crece un poco más. En el computador el continuo se aproxima con pasos pequeños mediante el método de Euler.

7. ¿Qué función cumple (Δt)?

Es el tamaño del paso de la aproximación de Euler. Un Δt más pequeño da un resultado más preciso, más cercano a $P_0 \cdot e^{rt}$, a cambio de más cálculos. Con $\Delta t = 1$ el modelo continuo se convierte en el discreto.

8. ¿Por qué es importante visualizar los resultados mediante gráficas?

Porque permiten ver de un vistazo tendencias, diferencias entre modelos, la dispersión producida por el ruido y el ajuste a los datos, aspectos difíciles de detectar en una tabla de números.

9. ¿Qué modelo presenta comportamiento aleatorio?

Solo el modelo estocástico, por el término $\varepsilon_t \sim N(0, \sigma^2)$.

10. ¿Cómo cambia la simulación cuando se introduce un nuevo arreglo de datos?

Cambian los parámetros estimados (P_0 , r y σ) y, por lo tanto, todas las curvas. Por ejemplo, con [2100, 1900, 1750, 1600, 1400, 1300, 1150] se obtiene $r = -0.0953$ y $\sigma = 32.54$, y los cuatro modelos muestran decrecimiento. El programa acepta cualquier arreglo por línea de comandos.

8. Conclusiones

- Los cuatro paradigmas describen el mismo fenómeno, pero sus supuestos (tiempo discreto o continuo, con o sin aleatoriedad) producen resultados distintos.
- Para datos observados por período, el modelo discreto es el más adecuado (MAE 23.07). El continuo requiere usar la tasa continua equivalente $\ln(1 + r)$ para ser comparable.
- El método de Euler aproxima el modelo continuo con un error que disminuye al reducir Δt . Con $\Delta t = 1$ coincide con el modelo discreto.
- La aleatoriedad no cambia la tendencia del sistema, sino su incertidumbre. Por eso un modelo estocástico debe evaluarse con muchas corridas y no con una sola.

9. Recomendaciones

- Fijar una semilla aleatoria al simular modelos estocásticos, para que los resultados sean reproducibles y verificables.
- Estimar r de forma coherente con el tipo de modelo: tasa por período para el discreto y $\ln(1 + r)$ para el continuo.
- Considerar un modelo logístico, con capacidad de carga, para simulaciones a largo plazo, ya que el exponencial crece sin límite.
- Integrar la visualización en NetLogo mediante pyNetLogo, mencionada en la guía, para observar el comportamiento del sistema de forma interactiva.

10. Bibliografía / Referencias

- [1] J. O. Guamán Q., “Diapositivas semana 2 – Introducción a la Simulación,” Universidad Nacional de Loja, 2026.
- [2] A. M. Law, *Simulation Modeling and Analysis*, 5th ed. New York, NY, USA: McGraw-Hill, 2015.
- [3] J. Banks, J. S. Carson, B. L. Nelson y D. M. Nicol, *Discrete-Event System Simulation*, 5th ed. Upper Saddle River, NJ, USA: Pearson, 2010.
- [4] C. R. Harris *et al.*, “Array programming with NumPy,” *Nature*, vol. 585, pp. 357–362, 2020.
- [5] J. D. Hunter, “Matplotlib: A 2D graphics environment,” *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90–95, 2007.

11. Anexos

Código fuente

El código completo está en el repositorio github.com/ivecanahi/simulacion-practicas, carpeta Unidad1/practica02. Se ejecuta con:

```
pip install -r requirements.txt
cd Unidad1/practica02
python3 main.py                # datos de la guía
python3 main.py 2100 1900 1750 1600 # otro arreglo de datos
python3 -m unittest test_model.py # pruebas
```

Fragmento de los modelos estocástico y continuo (model.py):

```
def stochastic_model(p0, r, sigma, time, rng=None):
    rng = rng if rng is not None else np.random.default_rng()
    population = [p0]
    for _ in range(time):
        noise = rng.normal(0, sigma)
        current = population[-1]
        new_population = current + r * current + noise
        population.append(max(new_population, 0.0))
    return np.arange(time + 1), np.array(population, dtype=float)

def continuous_model(p0, r, time, dt):
    steps = int(round(time / dt))
    t = np.linspace(0, steps * dt, steps + 1)
    population = [p0]
    for _ in range(steps):
        current = population[-1]
        population.append(current + dt * (r * current))
    return t, np.array(population, dtype=float)
```