

# Reporte Técnico de Actividades Práctico-Experimentales Nro. 002

## 1. Datos de Identificación del Estudiante y la Práctica

|                                       |                                                                                                                                                                                            |
|---------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Nombre del estudiante(s)              | Ivett Anahi Zaragocin Mora                                                                                                                                                                 |
| Asignatura                            | Simulación                                                                                                                                                                                 |
| Ciclo                                 | 5                                                                                                                                                                                          |
| Unidad                                | U1: Introducción a la Simulación                                                                                                                                                           |
| Resultado de aprendizaje de la unidad | R1. Aplica análisis estadísticos de los datos de la Simulación para mejorar la calidad de los resultados, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad. |
| Práctica Nro.                         | 02                                                                                                                                                                                         |
| Título de la Práctica                 | Comparación de modelos determinísticos, estocásticos, discretos y continuos                                                                                                                |
| Nombre del Docente                    | José Oswaldo Guamán Quinche                                                                                                                                                                |
| Fecha                                 | 08 y 09 de octubre de 2026                                                                                                                                                                 |
| Horario                               | Jueves 10h30 a 11h30 · Viernes 07h30 a 09h30                                                                                                                                               |
| Lugar                                 | Aula                                                                                                                                                                                       |
| Tiempo planificado en el Sílabo       | 3 horas                                                                                                                                                                                    |

## 2. Objetivo(s) de la Práctica

**Objetivo general:** diferenciar los principales paradigmas de simulación mediante la construcción de modelos computacionales.

**Objetivos específicos:**

1. Implementar un modelo determinístico y uno estocástico.
2. Comparar modelos discretos y continuos.
3. Analizar el efecto de la aleatoriedad sobre los resultados.

## 3. Materiales, Reactivos, Equipos y Herramientas

**Materiales y reactivos:**

- Python 3.12.
- NumPy 1.26: cálculo numérico y generación de números aleatorios [1].
- Matplotlib 3.9: generación de las gráficas [2].
- Datos de la guía: población observada en 7 períodos, [1000, 1100, 1250, 1400, 1600, 1850, 2100].

**Equipos y herramientas:**

- Computador con sistema operativo Linux.
- Editor de código y Git/GitHub para el control de versiones.

## 4. Marco Conceptual

### 4.1 Paradigmas de simulación

Un modelo de simulación representa el comportamiento de un sistema mediante variables, parámetros, ecuaciones y reglas [3]. Según su naturaleza, se clasifica en dos dimensiones [4]:

- **Determinístico o estocástico:** el determinístico no contiene componentes aleatorios, por lo que sus salidas quedan totalmente definidas por las entradas. El estocástico incluye variables aleatorias, así que sus salidas son también aleatorias y deben tratarse como estimaciones.
- **Discreto o continuo:** en el discreto las variables de estado cambian solo en instantes separados del tiempo. En el continuo cambian de forma permanente y suelen describirse con ecuaciones diferenciales.

En esta práctica el sistema de estudio es el **crecimiento poblacional**, que se modela con los cuatro paradigmas.

### 4.2 Crecimiento exponencial (modelo determinístico)

Malthus planteó que, sin restricciones, una población crece en proporción a su tamaño [5]. Esta idea se expresa con la ecuación diferencial  $dP/dt = rP$ , cuya solución exacta es:

$$P(t) = P_0 \cdot e^{rt}$$

donde  $P_0$  es la población inicial,  $r$  la tasa de crecimiento y  $t$  el tiempo. El modelo supone recursos ilimitados. Verhulst corrigió esa limitación con el modelo logístico, que añade una capacidad de carga máxima del ambiente [6].

### 4.3 Modelo discreto

Cuando la población se observa o se reproduce por períodos (generaciones, años), es natural modelarla con una ecuación en diferencias:

$$P_{t+1} = P_t + r \cdot P_t = (1 + r) \cdot P_t \implies P_t = P_0(1 + r)^t$$

Los modelos discretos pueden mostrar comportamientos muy distintos a sus equivalentes continuos. May demostró que ecuaciones en diferencias muy simples pueden producir incluso oscilaciones y caos [7].

### 4.4 Modelo continuo y método de Euler

Muchas ecuaciones diferenciales no tienen solución exacta y se resuelven numéricamente. El método de Euler avanza la solución con pasos de tamaño  $\Delta t$ , usando la pendiente en el punto actual [8]:

$$P_{t+\Delta t} = P_t + \Delta t \cdot (r \cdot P_t)$$

Euler es un método de **primer orden**: su error global es proporcional a  $\Delta t$ , por lo que al reducir el paso a la mitad el error también se reduce aproximadamente a la mitad [8].

### 4.5 Modelo estocástico

Las poblaciones reales fluctúan por factores que el modelo no considera (clima, enfermedades, migración). Esta **estocasticidad ambiental** se representa sumando un término aleatorio [9]:

$$P_{t+1} = P_t + r \cdot P_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma^2)$$

donde  $\sigma$  mide el nivel de variabilidad. Como cada ejecución da un resultado distinto, el modelo se analiza repitiéndolo muchas veces y estudiando la distribución de los resultados. Esta es la base del **método de Monte Carlo** [10]. Para el caso continuo, el método de Euler se generaliza al método de Euler–Maruyama, usado para simular ecuaciones diferenciales estocásticas [11].

#### 4.6 Números pseudoaleatorios y reproducibilidad

Los computadores generan números **pseudoaleatorios** con algoritmos deterministas a partir de una semilla. NumPy usa por defecto el generador PCG64, de la familia PCG, que combina buena calidad estadística con rapidez [12], [1]. Fijar la semilla permite repetir exactamente una simulación estocástica, condición necesaria para verificar sus resultados [13].

#### 4.7 Métricas de error

Para comparar cada modelo con los datos se usan el error medio absoluto (MAE) y la raíz del error cuadrático medio (RMSE):

$$MAE = (1/n) \sum |y_i - \hat{y}_i|, \quad RMSE = \sqrt{(1/n) \sum (y_i - \hat{y}_i)^2}$$

El MAE es más fácil de interpretar como error promedio [14]. El RMSE penaliza más los errores grandes y es adecuado cuando los errores siguen una distribución normal [15]. Reportar ambos da una visión más completa.

### 5. Procedimiento / Metodología Ejecutada

1. **Análisis de los datos.** Se calculó la tasa de crecimiento observada en cada período,  $(P_{t+1} - P_t)/P_t$ :

| Período | 0→1    | 1→2    | 2→3    | 3→4    | 4→5    | 5→6    |
|---------|--------|--------|--------|--------|--------|--------|
| Tasa    | 0.1000 | 0.1364 | 0.1200 | 0.1429 | 0.1563 | 0.1351 |

2. **Estimación de parámetros.**

- $P_0 = 1000$  (primer dato).
- $r = 0.1318$ : promedio de las seis tasas.
- $\sigma = 24.50$ : desviación estándar del residuo entre cada dato y la predicción del modelo discreto un paso adelante. Representa la variabilidad que el modelo discreto no explica.
- tiempo = 6 períodos y  $\Delta t = 0.1$  para el modelo continuo.

3. **Implementación.** Se programaron los cuatro modelos en Python siguiendo el pseudocódigo de la guía, con arquitectura Modelo-Vista-Controlador (MVC): `model.py` contiene los modelos, `controller.py` los datos y escenarios, `view.py` las tablas y gráficas, y `main.py` une el flujo. En el modelo estocástico, si la población queda negativa se fija en 0. Se usó la semilla 42.

4. **Verificación.** Se escribieron 12 pruebas unitarias con `unittest` que comprueban propiedades conocidas de cada modelo [13]:

- El estocástico con  $\sigma = 0$  es idéntico al discreto.
- Euler con  $\Delta t = 1$  es idéntico al discreto.
- Euler con  $\Delta t = 0.001$  se aproxima a  $P_0 \cdot e^{rt}$ .
- Con la misma semilla, el estocástico da el mismo resultado.
- El programa rechaza datos inválidos (un solo dato o poblaciones menores o iguales a 0).

5. **Comparación.** Se ejecutaron los cuatro modelos y se compararon con los datos mediante MAE y RMSE.

6. **Escenarios de análisis.** Se estudiaron tres efectos:

- La tasa  $r$ : siete valores entre  $-0.20$  y  $0.20$ .
- El ruido  $\sigma$ : 12.3, 24.5 y 98.0, con 30 corridas cada uno, más una verificación con 1000 corridas.
- El paso  $\Delta t$ : 1, 0.5, 0.1 y 0.01.

## 6. Resultados

### 6.1 Población por período

| t | Datos | Determinístico | Discreto | Estocástico | Continuo (Euler) |
|---|-------|----------------|----------|-------------|------------------|
| 0 | 1000  | 1000.0         | 1000.0   | 1000.0      | 1000.0           |
| 1 | 1100  | 1140.8         | 1131.8   | 1139.2      | 1139.9           |
| 2 | 1250  | 1301.5         | 1280.9   | 1263.9      | 1299.3           |
| 3 | 1400  | 1484.8         | 1449.7   | 1448.8      | 1481.0           |
| 4 | 1600  | 1694.0         | 1640.7   | 1662.7      | 1688.1           |
| 5 | 1850  | 1932.5         | 1856.9   | 1834.0      | 1924.2           |
| 6 | 2100  | 2204.7         | 2101.6   | 2043.8      | 2193.4           |

### 6.2 Error frente a los datos

| Modelo                                         | MAE          | RMSE         |
|------------------------------------------------|--------------|--------------|
| Determinístico                                 | 65.49        | 73.81        |
| <b>Discreto</b>                                | <b>23.07</b> | <b>29.61</b> |
| Estocástico (una corrida)                      | 33.83        | 40.47        |
| Continuo (Euler, $\Delta t = 0.1$ )            | 60.85        | 68.22        |
| Determinístico con $r_c = \ln(1 + r) = 0.1238$ | 23.07        | 29.61        |




Figura 1. Los cuatro modelos frente a los datos observados.

**Interpretación.** El modelo discreto es el que mejor se ajusta a los datos (MAE 23.07), porque los datos son observaciones por período y  $r$  se estimó como tasa por período. El determinístico y el continuo sobreestiman la población ( $\approx 2200$  frente a 2100 en  $t = 6$ ). La causa es que, con la misma  $r$ , el factor de crecimiento continuo por período es  $e^r = 1.1409$ , mayor que el discreto  $1 + r = 1.1318$ , porque el crecimiento continuo se acumula a cada instante. Si el modelo determinístico usa la **tasa continua equivalente**  $r_c = \ln(1 + r) = 0.1238$ , reproduce exactamente al discreto en los períodos enteros y obtiene el mismo error (última fila de la tabla). Es decir, discreto y continuo no se contradicen: solo usan tasas definidas de forma distinta.

### 6.3 Influencia de la tasa $r$




Figura 2. Influencia de la tasa  $r$ : crecimiento ( $r > 0$ ), equilibrio ( $r = 0$ ) y decrecimiento ( $r < 0$ ).

| $r$       | Población en $t = 6$ | Comportamiento         | Tiempo de duplicación |
|-----------|----------------------|------------------------|-----------------------|
| $+0.20$   | 2986                 | Crecimiento            | 3.8 periodos          |
| $+0.1318$ | 2102                 | Crecimiento (estimado) | 5.6 periodos          |
| $+0.05$   | 1340                 | Crecimiento            | 14.2 periodos         |
| $0.00$    | 1000                 | Constante              | —                     |
| $-0.05$   | 735                  | Decrecimiento          | —                     |
| $-0.10$   | 531                  | Decrecimiento          | —                     |
| $-0.20$   | 262                  | Decrecimiento          | —                     |

La tasa determina la dirección y la velocidad del cambio. El tiempo de duplicación del modelo discreto es  $\ln 2 / \ln(1 + r)$ : con la tasa estimada, la población se duplica cada 5.6 periodos, lo que coincide con los datos (de 1000 a 2100 en 6 periodos). Como el crecimiento es exponencial, pasar de  $r = 0.1318$  a  $r = 0.20$  aumenta la población final en un 42 %. Con  $r < 0$  la población decrece hacia 0 sin volverse negativa, porque cada período se multiplica por  $1 + r$ , que sigue siendo positivo.

## 6.4 Efecto de la aleatoriedad ( $\sigma$ )




Figura 3. Efecto del nivel de ruido  $\sigma$ : 30 corridas del modelo estocástico para  $\sigma = 12.3, 24.5$  y  $98.0$ .

| $\sigma$ | Corridas | Media en $t = 6$ | Desv. estándar | Mínimo                 | Máximo |
|----------|----------|------------------|----------------|------------------------|--------|
| 12.3     | 30       | 2096.1           | 27.9           | 2055.0                 | 2171.1 |
| 24.5     | 30       | 2110.6           | 84.0           | 1905.6                 | 2257.1 |
| 98.0     | 30       | 2067.7           | 380.9          | 1025.0                 | 2695.1 |
| 24.5     | 1000     | 2099.5           | 85.8           | 95 %: [1919.3, 2262.6] |        |

Al aumentar  $\sigma$ , las trayectorias se separan cada vez más y la desviación estándar de la población final crece de 28 a 84 y a 381. Con  $\sigma = 98$  incluso hay corridas que terminan cerca de la población inicial (1025) aunque  $r > 0$ . Sin embargo, la **media** se mantiene cerca del valor del modelo discreto (2101.6), porque el ruido tiene media 0. Con 1000 corridas la media converge a 2099.5, y el 95 % de los resultados queda entre 1919 y 2263. La aleatoriedad no cambia la tendencia del sistema: cambia la **incertidumbre** del resultado [9], [10].

## 6.5 Discreto frente a continuo: efecto de $\Delta t$




Figura 4. Efecto del tamaño de paso  $\Delta t$  en el modelo continuo, frente a la solución exacta.

| $\Delta t$ | Pasos | P(6) con Euler | Error absoluto | Error relativo |
|------------|-------|----------------|----------------|----------------|
| 1          | 6     | 2101.6         | 103.16         | 4.68 %         |
| 0.5        | 12    | 2150.4         | 54.34          | 2.46 %         |
| 0.1        | 60    | 2193.4         | 11.35          | 0.52 %         |
| 0.01       | 600   | 2203.6         | 1.15           | 0.05 %         |
| Exacta     |       | 2204.7         | —              | —              |

Con  $\Delta t = 1$ , Euler es idéntico al modelo discreto. Al reducir  $\Delta t$  el error disminuye de forma casi proporcional: al dividir  $\Delta t$  para 10, el error también se divide aproximadamente para 10 (11.35  $\rightarrow$  1.15). Esto confirma que Euler es un método de primer orden [8]. La elección de  $\Delta t$  es un compromiso entre precisión y costo de cálculo:  $\Delta t = 0.01$  requiere 600 pasos para un error menor al 0.1 %.

## 7. Preguntas de Control

### 1. ¿Qué representa el arreglo de entrada?

La población observada del sistema real en 7 periodos consecutivos. De él se obtienen los parámetros  $P_0$ ,  $r$  y  $\sigma$ , y sirve como referencia para medir el error de cada modelo.

### 2. ¿Cuál es la diferencia entre un modelo determinístico y uno estocástico?

El determinístico siempre produce el mismo resultado con los mismos parámetros. El estocástico incluye una variable aleatoria ( $\epsilon$ ), por lo que cada ejecución da un resultado distinto y debe analizarse con varias corridas (promedio y dispersión) [4], [10].

### 3. ¿Qué efecto produce modificar la tasa ( $r$ )?

Controla la dirección y la velocidad del cambio: una  $r$  mayor produce un crecimiento más rápido,  $r = 0$  mantiene la población constante y  $r < 0$  produce decrecimiento. Por ser un modelo exponencial, una diferencia pequeña en  $r$  se amplifica con el tiempo.

#### 4. ¿Qué representa el parámetro $\sigma$ ?

Es la desviación estándar del ruido  $\varepsilon$ : el nivel de variabilidad o incertidumbre del sistema, causado por factores que el modelo no considera (clima, enfermedades, migración) [9].

#### 5. ¿Qué ocurre cuando aumenta el nivel de ruido?

Las trayectorias se separan más entre sí y del modelo sin ruido, y aumenta la incertidumbre del resultado final (de 28 a 381 de desviación al pasar de  $\sigma = 12.3$  a  $\sigma = 98$ ). La tendencia promedio no cambia, porque el ruido tiene media 0.

#### 6. ¿Cuál es la diferencia entre los modelos discreto y continuo?

El discreto actualiza la población a saltos, una vez por período. El continuo supone que cambia en todo instante ( $dP/dt = rP$ ), por lo que, con la misma  $r$ , crece un poco más. En el computador el continuo se aproxima con pasos pequeños mediante el método de Euler [8].

#### 7. ¿Qué función cumple $(dt)$ ?

Es el tamaño del paso de la aproximación de Euler. Un  $\Delta t$  más pequeño da un resultado más preciso, más cercano a  $P_0 \cdot e^{rt}$ , a cambio de más cálculos. Con  $\Delta t = 1$  el modelo continuo se convierte en el discreto.

#### 8. ¿Por qué es importante visualizar los resultados mediante gráficas?

Porque permiten ver de un vistazo tendencias, diferencias entre modelos, la dispersión producida por el ruido y el ajuste a los datos, aspectos difíciles de detectar en una tabla de números.

#### 9. ¿Qué modelo presenta comportamiento aleatorio?

Solo el modelo estocástico, por el término  $\varepsilon_t \sim N(0, \sigma^2)$ .

#### 10. ¿Cómo cambia la simulación cuando se introduce un nuevo arreglo de datos?

Cambian los parámetros estimados ( $P_0$ ,  $r$  y  $\sigma$ ) y, por lo tanto, todas las curvas. Por ejemplo, con [2100, 1900, 1750, 1600, 1400, 1300, 1150] se obtiene  $r = -0.0953$  y  $\sigma = 32.54$ , y los cuatro modelos muestran decrecimiento. El programa acepta cualquier arreglo por línea de comandos.

## 8. Conclusiones

- Los cuatro paradigmas describen el mismo fenómeno, pero sus supuestos (tiempo discreto o continuo, con o sin aleatoriedad) producen resultados distintos.
- Para datos observados por período, el modelo discreto es el más adecuado (MAE 23.07). Las diferencias con el modelo continuo se deben a cómo se define la tasa. Con la tasa equivalente  $\ln(1 + r)$ , ambos coinciden.
- El método de Euler es de primer orden: su error disminuye en proporción a  $\Delta t$ . Con  $\Delta t = 1$  coincide con el modelo discreto, y con  $\Delta t = 0.01$  el error es menor al 0.1 %.
- La aleatoriedad no cambia la tendencia del sistema, sino su incertidumbre: la media de 1000 corridas (2099.5) coincide con el modelo discreto. Por eso un modelo estocástico debe evaluarse con muchas corridas y no con una sola.

- El modelo exponencial describe bien el crecimiento en el horizonte de los datos (6 períodos). Sin embargo, al no tener límite, no sería válido para proyecciones a largo plazo.

## 9. Recomendaciones

- Fijar una semilla aleatoria al simular modelos estocásticos, para que los resultados sean reproducibles y verificables [12], [13].
- Estimar  $r$  de forma coherente con el tipo de modelo: tasa por período para el discreto y  $\ln(1 + r)$  para el continuo.
- Usar un número alto de corridas (cientos o miles) para estimar con confianza la media y los intervalos de un modelo estocástico [10].
- Para proyecciones a largo plazo, reemplazar el modelo exponencial por el logístico de Verhulst, que incluye una capacidad de carga [6].
- Para mayor precisión en el modelo continuo, considerar métodos de orden superior como Runge–Kutta, que reducen el error sin necesidad de un  $\Delta t$  tan pequeño [8].
- Integrar la visualización en NetLogo mediante pyNetLogo, mencionada en la guía, para observar el comportamiento del sistema de forma interactiva.

## 10. Bibliografía / Referencias

- [1] C. R. Harris *et al.*, “Array programming with NumPy,” *Nature*, vol. 585, pp. 357–362, 2020.
- [2] J. D. Hunter, “Matplotlib: A 2D graphics environment,” *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90–95, 2007.
- [3] J. O. Guamán Quinche, “Diapositivas semana 2 – Introducción a la Simulación,” Universidad Nacional de Loja, 2026.
- [4] A. M. Law, *Simulation Modeling and Analysis*, 5th ed. New York, NY, USA: McGraw-Hill, 2015.
- [5] T. R. Malthus, *An Essay on the Principle of Population*. London, U.K.: J. Johnson, 1798.
- [6] P.-F. Verhulst, “Notice sur la loi que la population suit dans son accroissement,” *Correspondance Mathématique et Physique*, vol. 10, pp. 113–121, 1838.
- [7] R. M. May, “Simple mathematical models with very complicated dynamics,” *Nature*, vol. 261, pp. 459–467, 1976.
- [8] J. C. Butcher, *Numerical Methods for Ordinary Differential Equations*, 3rd ed. Chichester, U.K.: Wiley, 2016.
- [9] R. Lande, S. Engen y B.-E. Sæther, *Stochastic Population Dynamics in Ecology and Conservation*. Oxford, U.K.: Oxford University Press, 2003.
- [10] N. Metropolis y S. Ulam, “The Monte Carlo method,” *Journal of the American Statistical Association*, vol. 44, no. 247, pp. 335–341, 1949.
- [11] D. J. Higham, “An algorithmic introduction to numerical simulation of stochastic differential equations,” *SIAM Review*, vol. 43, no. 3, pp. 525–546, 2001.
- [12] M. E. O’Neill, “PCG: A family of simple fast space-efficient statistically good algorithms for random number generation,” Harvey Mudd College, Claremont, CA, USA, Tech. Rep. HMC-CS-2014-0905, 2014.

- [13] R. G. Sargent, "Verification and validation of simulation models," *Journal of Simulation*, vol. 7, no. 1, pp. 12–24, 2013.
- [14] C. J. Willmott y K. Matsuura, "Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance," *Climate Research*, vol. 30, pp. 79–82, 2005.
- [15] T. Chai y R. R. Draxler, "Root mean square error (RMSE) or mean absolute error (MAE)? – Arguments against avoiding RMSE in the literature," *Geoscientific Model Development*, vol. 7, pp. 1247–1250, 2014.

## 11. Anexos

### Anexo A. Código fuente

El código completo está en el repositorio [github.com/ivecanahi/simulacion-practicas](https://github.com/ivecanahi/simulacion-practicas), carpeta Unidad1/practica02. Se ejecuta con:

```
pip install -r requirements.txt
cd Unidad1/practica02
python3 main.py                # datos de la guía
python3 main.py 2100 1900 1750 1600 # otro arreglo de datos
python3 -m unittest test_model.py # pruebas
```

Modelos discreto, estocástico y continuo (model.py):

```
def discrete_model(p0, r, time):
    population = [p0]
    for _ in range(time):
        current = population[-1]
        population.append(current + r * current)
    return np.arange(time + 1), np.array(population, dtype=float)

def stochastic_model(p0, r, sigma, time, rng=None):
    rng = rng if rng is not None else np.random.default_rng()
    population = [p0]
    for _ in range(time):
        noise = rng.normal(0, sigma)
        current = population[-1]
        new_population = current + r * current + noise
        population.append(max(new_population, 0.0))
    return np.arange(time + 1), np.array(population, dtype=float)

def continuous_model(p0, r, time, dt):
    steps = int(round(time / dt))
    t = np.linspace(0, steps * dt, steps + 1)
    population = [p0]
    for _ in range(steps):
        current = population[-1]
        population.append(current + dt * (r * current))
    return t, np.array(population, dtype=float)
```

## Anexo B. Salida del programa

```
Parametros estimados a partir de los datos:
P0    = 1000
r      = 0.1318 (promedio de (P(t+1)-P(t))/P(t))
sigma = 24.50 (desv. estandar del residuo del modelo discreto)
tiempo = 6 periodos, dt = 0.1
```

Error frente a los datos

| Modelo           | MAE   | RMSE  |
|------------------|-------|-------|
| Deterministico   | 65.49 | 73.81 |
| Discreto         | 23.07 | 29.61 |
| Estocastico      | 33.83 | 40.47 |
| Continuo (Euler) | 60.85 | 68.22 |

## Anexo C. Resultado de las pruebas unitarias

```
$ python3 -m unittest test_model.py
```

```
.....
```

```
-----
Ran 12 tests
```

```
OK
```